

Profit-Vorhersage im Global-Superstore-Datensatz

Aufbau und Validierung von Machine-Learning-Pipelines zur Vorhersage
des Gewinns je Bestellposition

Projektarbeit im Modul (4) Machine Learning (ADS-04)

Studiengang Applied Data Science

Digital Business University of Applied Sciences

Vorgelegt von: [Vor- und Nachname, Matrikelnummer]

Abgabedatum: [Datum der Abgabe]

Inhaltsverzeichnis

Zusammenfassung3

1 Einleitung3

2 Daten und Methoden4

 2.1 Datengrundlage, Integration und Datenqualität4

 2.2 Methodisches Vorgehen5

3 Ergebnisse5

 3.1 Explorative Analyse6

 3.2 Modellvergleich über die Pipelines6

 3.3 Hyperparameter-Tuning und Modellkomplexität7

 3.4 Finale Evaluation, Baselines und Robustheit8

 3.5 Struktur der Zielgröße und Vergleichsmaßstab ohne Modell9

4 Diskussion und Handlungsempfehlungen9

 4.1 Beantwortung der Forschungsfragen9

 4.2 Handlungsempfehlungen10

 4.3 Limitationen und Ausblick10

Quellenverzeichnis11

Verwendete Hilfsmittel11

Anhang11

Eigenständigkeitserklärung13

Zusammenfassung

Diese Arbeit prüft, wie genau sich der Gewinn (Profit) einer Bestellposition im Global-Superstore-Datensatz vorhersagen lässt. Grundlage sind 51.290 Bestellpositionen aus sieben Weltmärkten aus den Jahren 2011 bis 2014. Drei Transformationspipelines und sechs Regressionsalgorithmen werden mit einer 5-fachen Cross-Validation verglichen und danach optimiert. Eine Pipeline mit polynomialen Interaktionstermen verbessert die linearen Modelle von $R^2 = 0,34$ auf 0,71. Sie bildet den wichtigen wirtschaftlichen Zusammenhang zwischen Umsatz und Rabatt ab. Auf den Testdaten sind das lineare Interaktionsmodell ($R^2 = 0,663$) und der Random Forest (0,654) etwa gleich gut. Der Unterschied liegt innerhalb der Streuung zwischen den Folds. Bei einem gruppierten oder zeitlichen Split dreht sich die Reihenfolge um. Daraus folgen drei Empfehlungen für das Management: Rabatte über 25 Prozent sollen eine Profitprüfung auslösen. Für die Sub-Category tables soll eine Rabattobergrenze gelten. Verlustpositionen sollen mit einer Fachregel und nicht mit dem Regressionsmodell gekennzeichnet werden.

1 Einleitung

Der Global-Superstore-Datensatz von Tableau zeigt die weltweiten Verkäufe eines erfundenen Einzelhändlers. Er ist die Datengrundlage aus dem Kurs. Dahinter steht ein echtes wirtschaftliches Problem: 24,46 Prozent aller Bestellpositionen machen Verlust. In den Trainingsdaten sind es 24,35 Prozent. Für eine datenbasierte Unternehmenssteuerung müssen die wichtigen Werttreiber bekannt und messbar sein (Seiter 2019). Wenn ein Unternehmen den möglichen Gewinn schon bei der Auftragsannahme abschätzen kann, kann es Rabatte, Sortiment und Versandbedingungen gezielt steuern.

Diese Arbeit behandelt ein Vorhersageproblem (Prediction). Der Gewinn je Bestellposition (Profit, in US-Dollar) soll aus den übrigen Bestellmerkmalen als Zahl vorhergesagt werden. Das ist eine Regressionsaufgabe des überwachten Lernens. Aus dem wirtschaftlichen Problem entstehen drei Forschungsfragen.

RQ1: Wie genau lässt sich der Profit einer Bestellposition mit den Merkmalen vorhersagen, die zum Bestellzeitpunkt bekannt sind? Und wie gut ist ein Modell im Vergleich zu einfachen Vergleichsmaßstäben?

RQ2: Welche Kombination aus Transformationspipeline und Algorithmus liefert für neue Daten die besten Ergebnisse? Und wie zuverlässig ist dieser Vergleich?

RQ3: Welche Merkmale führen besonders oft zu Verlustgeschäften? Welche Empfehlungen lassen sich daraus ableiten?

Kapitel 2 erklärt die Daten, ihre Qualität und die verwendeten Methoden. Kapitel 3 zeigt die Ergebnisse. Kapitel 4 bespricht die Ergebnisse und gibt Handlungsempfehlungen. Die vollständige und reproduzierbare Analyse befindet sich als durchgehend ausführbares Jupyter-Notebook im begleitenden Repository (Anhang A).

2 Daten und Methoden

Dieses Kapitel erklärt zuerst die Datengrundlage. Es zeigt, wie die drei Quellblätter zusammengeführt wurden und wie ihre Qualität bewertet wurde. Danach folgt das methodische Vorgehen. Es orientiert sich an der Machine-Learning-Checkliste von Géron (2019). Der Ablauf reicht von der Aufteilung der Daten über die Transformationspipelines bis zur abschließenden Bewertung.

2.1 Datengrundlage, Integration und Datenqualität

Die Rohdaten stammen aus der Kursdatei global-superstore.xls. Sie enthält drei Blätter: Orders mit 51.290 Bestellpositionen und 24 Attributen von Januar 2011 bis Dezember 2014, Returns mit 1.173 Zeilen und 1.172 eindeutigen Bestellnummern sowie People, das hier nicht gebraucht wird. Die Retouren werden über die Order ID mit den Bestellpositionen verbunden. Davon sind 3.050 Positionen betroffen. Der Profit wurde nicht um Retouren korrigiert. Das schränkt die Genauigkeit ein (Kapitel 4.3). Die Prüfung zeigt keine inhaltlichen Duplikate. Nur das Attribut Postal Code ist systematisch unvollständig. Es fehlt bei allen 41.296 Bestellungen außerhalb der USA. Deshalb wird es entfernt, denn eine Schätzung der fehlenden Werte wäre inhaltlich nicht sinnvoll. Auffällig ist außerdem: Retournierte Positionen haben im Durchschnitt einen höheren ausgewiesenen Profit als andere Positionen (42,07 statt 27,82 USD). Auch das zeigt, dass Retouren im Profit nicht berücksichtigt sind. Weil die Dokumentation begrenzt ist, werden einige Merkmale selbst erklärt. Sales ist der bereits rabattierte Umsatz. Profit ist der Deckungsbeitrag der Position.

Zusätzlich entstehen fünf neue Merkmale (Zheng und Casari 2018, Kap. 1): Lieferdauer, Bestellmonat, Bestelljahr, Stückpreis und Versandkostenquote. Tabelle 1 gibt einen Überblick über alle Merkmale.

Merkmal	Typ	Bedeutung / Verwendung
Sales, Quantity, Discount	metrisch	rabattierter Umsatz (USD), Stückzahl, Rabattsatz (0–0,85)

Shipping Cost	metrisch	Versandkosten der Position (USD); nur in Pipeline B
shipping_days, order_month, order_year	metrisch	abgeleitet; geprüft, im Endmodell nicht verwendet
unit_price, ship_cost_ratio	metrisch	abgeleitet; geprüft, im Endmodell nicht verwendet
Ship Mode, Order Priority	nominal	Versandart (4), Priorität der Bestellung (4)
Segment, Market	nominal	Kundensegment (3), Weltmarkt (7)
Category, Sub-Category	nominal	Produktkategorie (3), Unterkategorie (17)
Profit	metrisch	Zielgröße: Gewinn der Bestellposition (USD)

Tabelle 1: Erzeugte Merkmale und Merkmale des Endmodells. Die abgeleiteten Merkmale werden geprüft, aber später nicht verwendet (Kapitel 3.2).

2.2 Methodisches Vorgehen

Das Vorgehen folgt der Machine-Learning-Checkliste von Géron (2019, Kap. 2) und der ETL+-Struktur des Kursskripts (Impact Distillery 2026). Direkt nach der Aufbereitung werden die Daten geteilt: 80 Prozent sind Trainingsdaten und 20 Prozent Testdaten. Das sind 41.032 beziehungsweise 10.258 Positionen bei `random_state = 42`. Alle explorativen Analysen und alle Modellentscheidungen nutzen nur die Trainingsdaten.

Die Vorverarbeitung nutzt drei Transformationspipelines als `ColumnTransformer`. Dadurch bilden Vorverarbeitung und Modell ein gemeinsames Objekt. Die Skalierungswerte werden in jedem Validierungsfold nur aus dem jeweiligen Trainingsteil berechnet (Pedregosa et al. 2011). Pipeline A ist die Basis. Sie ersetzt fehlende Werte durch den Median und standardisiert Sales, Quantity und Discount. Die sechs nominalen Merkmale werden mit One-Hot-Encoding kodiert. Pipeline B ergänzt $\log_{1p}(\text{Sales})$ und die fünf abgeleiteten Merkmale. Pipeline C bildet polynomiale Merkmale aus den numerischen Basismerkmalen. So entsteht auch der Term $\text{Sales} \times \text{Discount}$. Verglichen werden sechs Regressoren aus dem Kurs: lineare Regression, Ridge, Lasso, kNN, Entscheidungsbaum und Random Forest. Für alle drei Pipelines gelten zuerst dieselben festen Hyperparameter. Der Vergleich nutzt eine 5-fache Cross-Validation mit KFold, Durchmischung, `random_state = 42` und R^2 als Metrik. Danach werden Ridge, kNN und Random Forest mit einer Rastersuche optimiert. Beim Entscheidungsbaum wird stattdessen die Baumtiefe untersucht. Die Modellauswahl stützt sich nur auf die Cross-Validation der Trainingsdaten. Die Testdaten werden erst für die letzte Bewertung und für klar gekennzeichnete Zusatzanalysen genutzt. Dazu gehören Vergleichsmaßstäbe, Robustheit, Merkmalswichtigkeit und Diagnostik. Aus diesen Zusatzanalysen werden keine Modellentscheidungen abgeleitet. Ein gepaarter t-Test über die Validierungsfolds und ein Bootstrap-Konfidenzintervall auf den Testdaten prüfen, ob die Unterschiede zwischen den Modellen belastbar sind.

3 Ergebnisse

Die Ergebnisse folgen dem Ablauf der Analyse. Zuerst werden Muster in den Daten gezeigt. Danach folgen der Vergleich der Pipelines und Algorithmen, ihre Feinabstimmung und die letzte Bewertung mit den Testdaten. Kapitel 3.5 untersucht zusätzlich, wie der Profit im Datensatz entsteht.

3.1 Explorative Analyse

Die Zielgröße Profit ist stark rechtsschief. Der Mittelwert liegt bei 28,66 USD, der Median bei 9,33 USD und die Standardabweichung bei 174,77 USD. Die Werte reichen von -4.088 bis 8.400 USD. Sales hat mit $r = 0,50$ den stärksten Zusammenhang mit Profit. Danach folgen Stückpreis ($0,43$), Versandkosten ($0,37$) und Discount ($-0,32$). Die Lieferdauer hat mit $r = 0,004$ praktisch keinen Einfluss.

Abbildung 1 zeigt den wichtigsten Befund für jede genaue Rabattstufe. Ohne Rabatt liegt der mittlere Profit bei $61,02$ USD je Position. Bei 20 Prozent Rabatt sind es noch $24,47$ USD und bei 25 Prozent $9,62$ USD. Der Wendepunkt liegt zwischen 25 und 27 Prozent. Bei 27 Prozent beträgt der mittlere Profit $-2,75$ USD und bei 30 Prozent $-60,06$ USD. Beim Sortiment fällt die Unterkategorie tables auf. Sie ist mit durchschnittlich $-80,92$ USD je Position die einzige Unterkategorie mit einem negativen Mittelwert. Copiers mit $120,98$ USD und appliances mit $82,80$ USD sind am profitabelsten. Die Auswertung nach Rabattstufen zeigt aber ein anderes Bild: Ohne Rabatt erreicht tables $+292,86$ USD je Position und ist damit der profitabelste Bereich. Erst bei mehr als 20 Prozent Rabatt wird der Wert negativ. Bei 20 bis 40 Prozent liegt er bei $-170,44$ USD und bei mehr als 60 Prozent bei $-644,95$ USD. Der Verlust entsteht also durch die Rabatte und nicht durch die Kalkulation.




Abbildung 1: Profit je Bestellposition und Durchschnitt für jede genaue Rabattstufe. Die Punktgröße zeigt die Fallzahl in den Trainingsdaten.

3.2 Modellvergleich über die Pipelines

Tabelle 2 zeigt die mittleren R^2 -Werte der 5-fachen Cross-Validation und die Streuung zwischen den Folds. Die Interaktionsterme verbessern die linearen Modelle stark: R^2 steigt von 0,339 auf 0,714. Das bestätigt die wirtschaftliche Bedeutung von Sales $\times$ Discount. Pipeline B fällt dagegen auf 0,322. Weil sich Pipeline B in mehreren Punkten von Pipeline A unterscheidet, wird ein einzelner Effekt getrennt geprüft. Wenn in Pipeline A nur Sales durch $\log_{1p}(\text{Sales})$ ersetzt wird, fällt R^2 auf 0,163. Die fünf abgeleiteten Merkmale bringen allein keinen zusätzlichen Nutzen. Deshalb werden sie im Endmodell nicht verwendet.

Modell	Pipeline A	Pipeline B	Pipeline C
Lineare Regression / Ridge	0,339 $\pm$ 0,113	0,322 $\pm$ 0,058	0,714 $\pm$ 0,044
Lasso	0,334 $\pm$ 0,101	0,317 $\pm$ 0,052	0,710 $\pm$ 0,045
k-Nearest-Neighbors	0,537 $\pm$ 0,117	0,470 $\pm$ 0,102	0,645 $\pm$ 0,056
Entscheidungsbaum	0,562 $\pm$ 0,161	0,566 $\pm$ 0,165	0,549 $\pm$ 0,199
Random Forest	0,699 $\pm$ 0,070	0,687 $\pm$ 0,073	0,687 $\pm$ 0,077

Tabelle 2: Mittleres R^2 der 5-fachen Cross-Validation und Standardabweichung zwischen den Folds auf den Trainingsdaten.

Die Streuung zwischen den Folds liegt zwischen 0,045 und 0,203. Sie ist damit viel größer als der Abstand von 0,023 zwischen den besten Modellen. Der gepaarte t-Test bestätigt das Ergebnis. Beim Vergleich des linearen Interaktionsmodells mit dem Random Forest ergibt sich $p = 0,515$. Der Unterschied ist also nicht signifikant.

3.3 Hyperparameter-Tuning und Modellkomplexität

Für Pipeline C werden drei Modellfamilien mit einer Rastersuche optimiert. Ridge erreicht mit $\alpha = 0,01$ ein CV- R^2 von 0,714. kNN erreicht mit $k = 10$ einen Wert von

0,651. Der Random Forest erreicht mit $\text{max_depth} = 12$ einen Wert von 0,692. Das Raster für α reicht bis 100.000. Bis 100 bleibt die Modellgüte gleich. Erst bei 10.000 fällt sie auf 0,608. Bei 41.032 Beobachtungen und 47 Merkmalen zeigen die linearen Modelle damit kein Overfitting. Deshalb liefern Ridge und die lineare Regression ohne Regularisierung dieselben Werte.

Zusätzlich wird der Grad der polynomialen Merkmale optimiert. Bisher war er fest auf zwei gesetzt. Grad drei erreicht ein CV-R^2 von 0,748 statt 0,714. Der gepaarte t-Test ergibt $p = 0,006$. Das ist der einzige statistisch abgesicherte Modellunterschied der Arbeit. Er betrifft die Konstruktion der Merkmale und nicht den Algorithmus. Beim Entscheidungsbaum ersetzt eine Analyse der Komplexität die Rastersuche. Der Trainings-Score steigt durchgehend von 0,317 auf 0,977. Der Validierungs-Score ist bei Tiefe acht am höchsten und liegt dort bei $0,562 \pm 0,200$. Bei Tiefe 20 fällt er auf 0,425. Wegen der großen Streuung ist das Maximum nicht zuverlässig. Nach der Ein-Standardfehler-Regel wäre schon Tiefe vier vertretbar.

3.4 Finale Evaluation, Baselines und Robustheit

Tabelle 3 bewertet die Modelle mit den bis dahin unberührten Testdaten und zeigt zwei Vergleichsmaßstäbe. Die Mittelwert-Baseline erreicht $R^2 = -0,000002$ und einen MAE von 67,52 USD. Die sehr kleine Abweichung von null zeigt, dass der Split repräsentativ ist. Ein einfaches Modell nur mit Sales und Discount erreicht bereits $R^2 = 0,660$. Das vollständige Modell erreicht 0,663. Alle kategorialen Merkmale bringen zusammen also nur 0,003 R^2 . Ohne Sales fällt R^2 auf 0,49.

Modell (getunt)	Test- R^2	RMSE (USD)	MAE (USD)
Lineare Regression / Ridge	0,663	100,20	41,04 / 41,03
Vergleich: nur Sales + Discount	0,660	100,63	40,21
Random Forest (100; Tiefe 12)	0,654	101,58	35,81
kNN (k = 10)	0,637	104,05	39,94
Entscheidungsbaum (Tiefe 8)	0,607	108,24	38,01
Baseline: Mittelwert	0,000	172,63	67,52

Tabelle 3: Endgültige Modellgüte auf den Testdaten mit Pipeline C und zwei Vergleichsmaßstäben.

Beim robusten Fehlermaß MAE ändert sich die Reihenfolge. Der Random Forest ist mit 35,81 USD am besten. Die linearen Modelle liegen bei etwa 41,0 USD. Ein Bootstrap-Konfidenzintervall zeigt

einen klaren Unterschied zwischen den beiden Fehlermaßen. Beim R^2 enthält das Intervall die Null: Die Differenz beträgt +0,007 und das Intervall reicht von $-0,032$ bis $+0,067$. Beim MAE enthält es die Null nicht: Die Differenz beträgt +5,26 USD und das Intervall reicht von +4,28 bis +5,96. Zusätzlich prüfen ein gruppierter Split nach Order ID und ein zeitlicher Split die Robustheit. Das lineare Modell ist nur beim zufälligen Split vorn. In beiden strengerem Verfahren ist der Random Forest besser: 0,684 statt 0,645 beziehungsweise 0,755 statt 0,719.

Abbildung 2 zeigt die Bedeutung der Merkmale mit Permutation Importance. Discount mit 1,447 und Sales mit 1,353 sind mit großem Abstand am wichtigsten. Danach folgen Quantity mit 0,017 und Sub-Category mit 0,003.




Abbildung 2: Wichtigkeit der Merkmale mit Permutation Importance für das lineare Interaktionsmodell auf den Testdaten.

3.5 Struktur der Zielgröße und Vergleichsmaßstab ohne Modell

Die große Bedeutung von Umsatz und Rabatt führt zu einer weiteren Frage: Wie entsteht der Profit im Datensatz? Aus der kaufmännischen Rechnung folgt $\text{Profit} = \text{Sales} \cdot (m - d)/(1 - d)$. Dabei ist d der Rabattsatz und m die Rohmarge des Produkts. Wird m zurückgerechnet, beträgt die Standardabweichung innerhalb eines Produkts 0,0040. Über alle Produkte liegt sie bei 0,1490. Die Rohmarge ist damit für ein Produkt praktisch konstant. Wenn das Produkt bekannt ist, lässt sich der Profit deshalb eindeutig berechnen. Als Vergleichsmaßstab erreicht diese Formel mit einer einzigen global geschätzten Marge von 0,27 und ohne angepasste Parameter $R^2 = 0,736$ sowie einen MAE von 36,13 USD.

Sie ist damit besser als jedes Modell aus Tabelle 3. Mit produktspezifischen Margen aus den Trainingsdaten steigt R^2 auf 0,974 und der MAE fällt auf 3,71 USD. Die Formel hat aber eine Grenze: Das Produkt muss bereits im Sortiment sein. Auf 4,0 Prozent der Positionen im Testset trifft das nicht zu. Danach wird geprüft, ob Verlustpositionen schon bei der Auftragsannahme erkannt werden können. Bei dieser Klassifikationsaufgabe erreicht das lineare Regressionsmodell ein F-Maß von 0,717. Der Random Forest erreicht 0,844, die logistische Regression 0,848 und die Fachregel „Rabatt über 20 Prozent“ 0,849. Die Basisrate beträgt 24,9 Prozent. Weil der Profit mit dem Umsatz wächst, nimmt auch die Streuung der Fehler zu. Der Zusammenhang zwischen absolutem Residuum und Sales beträgt $r = 0,741$. Wenn statt des Profits die Marge modelliert wird, erreicht der Random Forest auf den Testdaten $R^2 = 0,747$ und einen MAE von 34,11 USD.

4 Diskussion und Handlungsempfehlungen

Im nächsten Schritt werden die drei Forschungsfragen beantwortet. Daraus entstehen Empfehlungen. Zum Schluss werden die Grenzen der Arbeit erklärt.

4.1 Beantwortung der Forschungsfragen

Zu RQ1: Der Profit lässt sich deutlich besser als mit einem Mittelwert vorhersagen. Wichtiger als die Wahl des Verfahrens ist aber die Struktur des Problems. Das beste trainierte Modell erklärt ungefähr zwei Drittel der Varianz und erreicht auf den Testdaten $R^2 = 0,663$. Es senkt den mittleren absoluten Fehler gegenüber der Mittelwert-Baseline von 67,52 auf 35,81 USD. Das entspricht 46,9 Prozent. Die Vergleichsmaßstäbe zeigen aber, dass einfachere Ansätze sehr stark sind. Zwei Merkmale erreichen 0,660. Die Formel ohne angepasste Parameter erreicht 0,736. Mit Produktmargen erreicht dieselbe Formel 0,974.

Zu RQ2: Pipeline C mit Interaktionstermen ist klar die beste Vorverarbeitung. Dieses Ergebnis gilt für alle Modelle und Splits. Mit Polynomgrad drei verbessert sich die Pipeline signifikant weiter ($p = 0,006$). Bei der Wahl des Algorithmus ist das Ergebnis weniger klar. Der Unterschied zwischen linearem Modell und Random Forest ist weder in der Cross-Validation ($p = 0,515$) noch im Bootstrap signifikant. Bei strengeren Splits dreht sich die Reihenfolge um. Sicher ist nur, dass der Random Forest beim typischen Fehler besser ist. Der Unterschied beim MAE beträgt 5,26 USD. In diesem Fall ist die Konstruktion der Merkmale wichtiger als die Wahl des Algorithmus.

Zu RQ3: Der Rabatt ist der wichtigste Grund für Verluste. Bei der Permutation Importance erreicht er mit 1,447 den höchsten Wert. Danach folgt der Umsatz mit 1,353. Alle anderen Merkmale liegen unter 0,02. Der Wendepunkt liegt zwischen 25 und 27 Prozent Rabatt. Auch die scheinbar unprofitable Unterkategorie tables hat vor allem ein Rabattproblem. Regionale Unterschiede sind weniger wichtig. EMEA erreicht 9,57 USD, Canada 46,55 USD.

4.2 Handlungsempfehlungen

Erstens sollen Rabatte über 25 Prozent eine Profitprüfung auslösen. Dort liegt der gemessene Wendepunkt. Bei 25 Prozent Rabatt beträgt der mittlere Profit noch +9,62 USD je Position. Bei 27 Prozent sind es bereits -2,75 USD und bei 30 Prozent -60,06 USD.

Zweitens soll für die Unterkategorie tables eine feste Rabattobergrenze gelten. Eine neue Kalkulation des Sortiments ist nicht nötig. Der mittlere Verlust entsteht nicht durch zu niedrige Preise, sondern durch die Rabattpolitik. Ohne Rabatt verdient der Bereich +292,86 USD je Position. Bei mehr als 60 Prozent Rabatt verliert er -644,95 USD.

Drittens sollen riskante Positionen bei der Auftragsannahme nicht mit dem Regressionsmodell gekennzeichnet werden. Für diese Ja-Nein-Entscheidung erreicht die Fachregel „Rabatt über 20 Prozent“ ein F-Maß von 0,849. Das lineare Modell erreicht nur 0,717. Die Regression bleibt trotzdem sinnvoll, wenn die erwartete Höhe des Gewinns gebraucht wird.

4.3 Limitationen und Ausblick

Der Datensatz ist erfunden. Einige Merkmale mussten selbst erklärt werden. Außerdem wurde die Zielgröße nicht um Retouren korrigiert. Die wichtigste Grenze betrifft aber die Aufgabe selbst. Der Profit folgt einer festen Rechnung aus Umsatz, Rabatt und Produktmarge. Der Modellvergleich misst deshalb weniger die allgemeine Leistung der Verfahren. Er misst vor allem, wie gut sie eine bekannte Formel nachbilden. Schwieriger wäre eine Vorhersage vor der Preisfestlegung. Ohne Sales erreicht R^2 nur 0,49. Auch neue Produkte wären eine schwierigere Aufgabe. Für spätere Arbeiten bieten sich Gradient Boosting und eine Klassifikationsvariante an.

Quellenverzeichnis

- Géron, A. (2019): Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow. 2. Auflage, O'Reilly, Sebastopol.
- Impact Distillery (2026): Kursskript ADS-04 — Machine Learning. Digital Business University of Applied Sciences. URL: ads.impactdistillery.com/ads-04 (letzter Abruf: 07.08.2026).
- Pedregosa, F.; Varoquaux, G.; Gramfort, A. et al. (2011): Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, S. 2825–2830.
- Seiter, M. (2019): Business Analytics. Wie Sie Daten für die Steuerung von Unternehmen nutzen. 2. Auflage, Vahlen, München.
- Zheng, A.; Casari, A. (2018): Feature Engineering for Machine Learning. O'Reilly, Sebastopol.
- Tableau Software (o. J.): Global Superstore Dataset (global-superstore.xls).
Bereitgestellt über das Kursmaterial ADS-04.

Verwendete Hilfsmittel

Für diese Arbeit werden folgende Hilfsmittel genutzt: Python 3 mit pandas, NumPy, scikit-learn und Matplotlib für die gesamte Analyse sowie Jupyter Notebook als Arbeitsumgebung. Ein KI-Sprachmodell hilft bei der Struktur des Codes, bei Formulierungen und bei der Literaturrecherche. Alle Entscheidungen zur Analyse, die Auswertung der Ergebnisse und die inhaltlichen Schlussfolgerungen werden selbstständig getroffen. Alle genannten Kennzahlen stammen aus den Notebook-Ausführungen im Repository. Code oder Lösungswege aus fremden Notebooks, zum Beispiel von Kaggle, werden nicht übernommen.

Anhang

Anhang A: Das Analyseprojekt liegt als GitHub-Repository unter <https://github.com/mohammed-hmed/ads04-profitvorhersage-superstore>. Es enthält die gesamte Analyse als ein durchgehend ausführbares Jupyter-Notebook unter `notebooks/ADS04_Gesamtanalyse.ipynb`. Das Notebook besteht aus neun aufeinander aufbauenden Teilen: 01 Datenaufbereitung, 02 explorative Analyse, 03 Modellvergleich, 04 Tuning, 05 Overfitting, 06 Testevaluation, 07 Struktur der

Zielgröße, 08 Signifikanz und 09 Diagnostik. Zusätzlich gibt es eine inhaltsgleiche Version ohne Fließtext unter ADS04_Gesamtanalyse_nur_Code.ipynb. Das Repository enthält außerdem Rohdaten, aufbereitete Daten, Abbildungen und Ergebnisdateien. Beide Notebooks sind vollständig ausgeführt und enthalten alle Ausgaben. Die Ausführungszähler laufen ohne Lücke von 1 bis 47.

Eigenständigkeitserklärung

Hiermit erkläre ich, dass ich die vorliegende Projektarbeit selbstständig und ohne unzulässige fremde Hilfe verfasst habe. Alle Stellen, die wörtlich oder sinngemäß aus veröffentlichten oder unveröffentlichten Quellen übernommen wurden, sind als solche kenntlich gemacht. Die verwendeten Hilfsmittel und Werkzeuge sind im gleichnamigen Abschnitt vollständig angegeben. Die Arbeit wurde in gleicher oder ähnlicher Form keiner anderen Prüfungsbehörde vorgelegt.

Ort, Datum

Unterschrift